

HLA 限制型免疫疗法的全球公平性分析

方海畅*

(中国人民公安大学, 北京 102623, China)

摘要:

【目的】免疫治疗药物 Tebentafusp 与 Afami-cel 均依赖 HLA-A*02:01 呈递肿瘤抗原, 而该等位基因在中国胃癌患者中频率仅约 5%, 东亚高频的 A*11:01 (46.9%) 与 A*24:02 (25.0%) 却无任何对应药物。本研究旨在量化 HLA 限制型免疫疗法在全球人群中的公平性差距, 并提出基于人群 HLA 分布的靶点优先级优化方案。

【方法】整合七个独立数据源: GBD 全球死因数据 (2000–2023 年)、GLOBOCAN 2022 胃癌负担数据、TCGA-STAD 胃癌突变数据 (178,508 条/393 例)、UniProt 蛋白序列数据、IEDB MHC-I 结合预测数据 (2,598 条突变肽段 x4 个 HLA 等位基因 = 10,392 次预测)、AFND/NMDP/Zhou (2019) HLA 人群频率数据及世界银行 WDI 经济数据。分析管线: 非沉默突变筛选 → 跨突变位点 9–11mer 肽段提取 → IEDB API 全矩阵结合预测 (percentile rank 判定) → 贪心覆盖算法优化靶点优先级。

【结果】A*11:01 的强结合新抗原数 (27 条) 为 A*02:01 (11 条) 的 2.5 倍; A*02:01 对 KRAS 的强结合肽段为零条, A*11:01 检出 5 条, A*03:01 检出 4 条。CDH1 与 SMAD4 仅 A*24:02 有强结合肽段, FBXW7 仅 A*11:01, ERBB3 仅 A*03:01。贪心优化后, 中国胃癌患者理论覆盖率从 FDA 现状的 5.0% 提升至 60.2% (12.4 倍), 欧洲仅从 26.0% 提升至 37.1% (1.4 倍)。HW 校正敏感性分析显示优化排序不变, 覆盖率稳定于 60%–72%。A*02:01 的 SB 数 (11 条) 低于随机期望值 (约 13 条, 富集倍数 0.85 倍)。

【局限】肽-MHC 结合预测不等于免疫原性, 需体外实验验证; 贪心覆盖假设各 HLA 独立分布, 可能存在连锁不平衡偏倚; TCGA-STAD 亚洲样本仅 87 例, 存在人群代表性局限。

【结论】HLA 限制型免疫疗法的研发方向存在结构性 A*02:01 偏好, 东亚人群最优靶点 A*11:01 与 A*24:02 从未进入研发管线。按贪心覆盖优化重排优先级后, 东亚覆盖率可提升 12.4 倍, 公平性差距显著缩小。

*E-mail: 202420410014@stu.ppsuc.edu.cn

关键词：HLA；免疫治疗；胃癌；新抗原；健康公平性；TCGA-STAD；贪心覆盖优化

中图分类号：Q811.4 **文献标识码：**A

1 引言

1.1 研究背景

免疫治疗正在改变肿瘤治疗的格局。2022 年和 2024 年, Tebentafusp 和 Afami-cel 先后获 FDA 批准, 成为实体瘤 TCR-T/CAR-T 疗法的里程碑 [1, 2]。但两款药物都依赖 HLA-A*02:01 呈递肿瘤抗原。问题出在 HLA 的全球分布上——A*02:01 在欧洲人群中频率约 27%, 在中国胃癌患者中仅约 5%, 而 A*11:01 频率高达 47%, A*24:02 达 25%。这两个东亚高频等位基因目前没有任何对应的免疫治疗药物。胃癌东亚负担最重 (全球 54% 病例), 其人群最不可能受益于现有的 HLA 限制型疗法。这不是医疗资源分配的问题, 是基因层面的系统性排斥。

1.2 研究问题

本研究回答三个递进问题: (1) HLA 频率差异有多大? (2) 东亚高频 HLA 是否真的能有效呈递胃癌新抗原? (3) 如果重排研发优先级, 能缩小多少公平性差距?

1.3 技术路线

分析管线以 TCGA-STAD[3] 的 178,508 条胃癌突变数据为起点, 经 UniProt[4] 蛋白序列提取、跨突变位点肽段生成, 通过 IEDB API[5] 完成 2,598 条独特突变肽段与 4 个 HLA 等位基因的全矩阵结合预测 (10,392 次), 预测方法为 NetMHCpan-4.1[6]。在此基础上用贪心覆盖算法进行靶点优先级优化。

数据层 (自下而上): GBD 死因数据 [7]+GLOBOCAN 2022[8]→TCGA-STAD 突变数据 →UniProt API→IEDB API→AFND[10]/NMDP/Zhou 等 (2019) [9]HLA 人群频率 → 世界银行 WDI 经济协变量。

2 数据与方法

2.1 数据来源

本研究整合了七个独立数据源，概况汇总于表 1。

表 1: 数据来源汇总

数据层	来源	类型	核心字段	规模
全球死因数据	GBD	CSV	国家、年份、死因、死亡人数	24 文件，203 国
胃癌负担	GLOBOCAN 2022	表格	国家、癌症部位、ASR	185 国
胃癌突变	TCGA-STAD (FireBrowse)	MAF	基因名、突变类型、蛋白改变	178,508 条
蛋白序列	UniProt REST API	FASTA	氨基酸序列	约 100 条
HLA-肽段结合	IEDB MHC-I API	TSV	allele、peptide、rank、IC50	10,392 次预测
HLA 人群频率	AFND/NMDP/Zhou 2019	CSV	allele、population、frequency	25 条记录
经济数据	世界银行 WDI	CSV	人均 GDP、卫生支出	2019–2024 出

全球死亡原因数据来自 GBD 2021[7]，覆盖 203 个国家 2000–2023 年。

胃癌疾病负担数据来自 GLOBOCAN 2022[8]，涵盖 185 个国家。

胃癌突变数据来自 TCGA-STAD 项目 [3]，通过 FireBrowse API 下载，包含 178,508 条突变记录、393 例胃癌样本。核心字段包括 Hugo_Symbol、Variant_Classification、Protein_Change (HGVS 命名) 及 SwissProt_entry_Id。

蛋白序列数据来自 UniProt REST API[4]，批量获取约 100 条人类蛋白全长序列。

HLA-肽段结合预测数据通过 IEDB MHC-I Binding Prediction API[5] 在线获取，共提交 2,598 条独特突变肽段 x4 个 HLA 等位基因 =10,392 次预测，获得 10,333 条有效结果。核心字段包括 allele、peptide、percentile_rank 和 IC50。

HLA 人群频率数据整合三个来源: Allele Frequency Net Database (AFND[10])、NMDP 以及 Zhou 等 (2019) [9] 发表的中国胃癌患者 HLA 实测分型数据 (n=96)。

经济数据来自世界银行 WDI，包含人均 GDP (现价美元)、卫生支出占 GDP 比例等指标。

2.2 数据预处理

原始 MAF 文件 178,508 条记录，筛选步骤如下：

(1) 过滤同义突变和非编码突变，保留错义突变 (Missense_Mutation)，得 135,763 条。

(2) 筛选复发突变。条件：错义突变、有明确蛋白改变标注 (p. 开头)、有 SwissProt ID、在至少 2 个患者中出现，压缩到约 1,640 个候选。加策略筛选：取 14 个已知胃癌驱动基因 (TP53、ARID1A、KRAS、PIK3CA、CDH1、ERBB2、RHOA、SMAD4、CTNNB1、APC、PTEN、FBXW7、ERBB3、MET) 中的所有突变，再加非驱动基因中出现至少 5 个患者的突变。

(3) 肽段提取。通过 UniProt API 获取全长蛋白序列，根据蛋白改变标注定位突变位置，提取跨越突变位点的 9–11mer 肽段。限定 9–11mer 的原因是 HLA-I 类肽段结合槽通常容纳 8–11 个氨基酸，其中 9mer 和 10mer 是最主要结合长度。最终得到 2,598 条独特突变肽段。

HLA 频率数据中，中国胃癌患者频率来自 Zhou 等 [9] 的 96 例实测分型——这是目前最直接匹配中国胃癌人群的频率参考。

2.3 新抗原-HLA 结合预测方法

采用 IEDB MHC-I Binding Prediction API[5]，底层调用 NetMHCpan 推荐方法 [6]。以 percentile rank 而非绝对 IC50 作为主要判定标准，在每个 MHC 内部归一化以减少训练集偏差。另加入 A*03:01 作为中性对照——其欧亚频率均约 10–15%。

结合判定分四档：强结合 SB (rank<0.5%)、弱结合 WB (<2.0%)、边缘结合 (<10.0%)、不结合。SB+WB 用于贪心覆盖输入。

工程方面，2,598 条肽段 x4 个 HLA=10,392 次 HTTP 请求，实测约需 4 小时 (约 19 条/分钟)。实现增量保存 (每 200 条结果写一次 CSV) 和断点续传。最终 10,392 次预测获得 10,333 条有效结果，仅 59 条失败 (5.7‰ 失败率)。

2.4 互补性与独有性分析

构建 14 个驱动基因 x4 个 HLA 的 SB 覆盖矩阵，逐基因检查每个 HLA 能强结合哪些驱动基因的突变肽段。若 A*02:01 覆盖的靶点均被其他 HLA 覆盖，则其在东亚人群中的价值几乎为零；反之，东亚高频 HLA 若有独有靶点，则这些是目前治疗版图上的盲区。

2.5 贪心覆盖优化算法

优化问题描述：有 N 个药物研发名额，应优先靶向哪些 HLA 才能在目标人群中覆盖最多患者？

贪心算法逻辑：每次选当前未覆盖人群中频率最高的 HLA，纳入优先级列表，更新累积覆盖率，直至饱和。使用等位基因频率而非 Hardy-Weinberg 校正携带率——有意的保守选择。以 HW 校正作为敏感性分析验证结论稳健性。

3 结果

3.1 全球肿瘤负担趋势

GBD 数据显示，全球肿瘤死亡从 2000 年的 703 万增长到 2023 年的 1,049 万，增幅 49.2%。同期消化系统疾病死亡从 204 万增至 240 万，增幅 17.8%——肿瘤的增速接近消化系统疾病的三倍，两者差距从 3.4 倍扩大到 4.4 倍。

东亚 2023 年肿瘤死亡约 379 万例，绝对负担全球最高；南亚增速最快（+131.7%）。撒哈拉以南非洲（+124.6%）和中东北非（+116.6%）的增速常被忽视——肿瘤负担正从高收入国家向中低收入国家快速转移。人均 GDP 与肿瘤报告死亡率呈正相关，背后是诊断能力和登记完整性的差异。

GLOBOCAN 2022 数据显示，东亚贡献了全球 53.8% 的胃癌新发病例，发病率是欧美的 5–8 倍，胃癌是全球第 5 高发癌症和第 5 大癌症死因。




图 1: 全球肿瘤死亡与消化系统疾病死亡趋势（2000–2023 年）

3.2 HLA 人群频率差异

如表2所示，A*02:01 在欧洲中位频率 26.0%，在中国胃癌患者中仅 5.0%；A*11:01 在中国胃癌患者中 46.9%，欧洲仅 5.6%。A*11:01 和 A*24:02 合计覆盖中国胃癌患者超 70%，对应的免疫治疗药物为零。疾病负担最重的东亚，HLA 基因型与现有药物靶点的错配最严重。




图 2: 七区域肿瘤死亡趋势对比




图 3: 人均 GDP 与肿瘤死亡率散点图

表 2: 主要 HLA 等位基因在东亚与欧洲人群中的频率对比

等位基因	中国胃癌患者 (Zhou 2019)	东亚一般人群 (NMDP)	欧洲人群 (AFND 中位)
A*02:01	5.0%	6.5%	26.0%
A*11:01	46.9%	—	5.6%
A*24:02	25.0%	—	10.0%




图 4: 肿瘤在各国死因中的排名变化 (2000 vs 2023)




图 5: 胃癌全球区域分布 (GLOBOCAN 2022)

3.3 新抗原-HLA 结合预测

全矩阵预测核心结果汇总于表3。A*11:01 的 SB 数 (27 条) 是 A*02:01 (11 条) 的 2.5 倍。A*03:01 同样有 27 条 SB——作为中性对照表现强劲, 反而加强了论证: 问题不在于技术难度, 而在于研发方向始终围绕 A*02:01。

每个 HLA 的随机期望假阳性 SB 约为 13 条 (2,585x0.5%)。A*02:01 的 11 条低于随机期望 (富集倍数 0.85x), A*11:01 (27 条, 2.1x) 和 A*03:01 (27 条, 2.1x) 显著高于随机水平——A*02:01 对胃癌突变肽段的强结合判定在统计学上无法与随机肽库区分。

表 3: 四个 HLA 等位基因的胃癌新抗原呈递能力

HLA 等位基因	强结合 SB	弱 + 强 SB+WB	覆盖基因 (SB+WB)	覆盖驱动基因 (SB)
A*02:01	11	62	21	4
A*11:01	27	71	19	6
A*24:02	13	44	15	6
A*03:01	27	67	19	6

注: SB: percentile rank<0.5%; WB: <2.0%。数据来源: IEDB API 全矩阵预测 (NetMHCpan-4.1), 10,333 条有效记录。

3.4 驱动基因 HLA 覆盖互补性

驱动基因层面的互补性是本分析最关键的发现。覆盖矩阵见表4。




图 6: TCGA-STAD 高频突变基因 (Top 20)

TP53 和 ERBB2 均被四个 HLA 全覆盖，每个等位基因都有强结合肽段检出。KRAS 则明显挑 HLA——A*11:01 检出 5 条 SB，A*03:01 检出 4 条，A*02:01 一条都没有 [11]。CDH1 和 SMAD4 这两个弥散型胃癌标志基因只在 A*24:02 里有强结合肽段，FBXW7 只在 A*11:01，ERBB3 只在 A*03:01，都是一个 HLA 单打独斗。A*02:01 虽然有 4 个驱动基因 (TP53、PIK3CA、ERBB2、CTNNB1)，但这四个基因其他 HLA 都能覆盖，在东亚人群中并无独占靶点。

KRAS 值得单独讨论。A*02:01 对 KRAS 突变肽段的强结合数为零——这是结构层面的不匹配，A*02:01 的 binding motif 与 KRAS G12D/G12V 等关键突变产生的肽段在 anchor 残基上不对接。A*11:01 (5 条 SB) 和 A*03:01 (4 条 SB) 都能有效呈递。KRAS 在胃癌中突变频率 8–12%，预后极差 [11]，现有 HLA 限制型疗法对这部分患者完全不适用，这不是数量差距，是有无问题。

3.5 靶点优先级优化

贪心覆盖优化结果见表5。中国队列从 A*11:01 起步 (46.9%)，加 A*24:02 后累计 60.2%，第三步加 A*02:01 仅涨 2%，边际增益很有限。欧洲队列的曲线平坦得多——从 A*02:01 起步 26.0%，每一步提升都不到 10%。

中国患者从 5.0% 提升到优化方案的 60.2%，翻了 12.4 倍。欧洲从 26.0% 到 37.1%，只有 1.4 倍。这个差距不是研发水平的差距，单纯是运气问题——A*02:01 恰好是欧洲人群的最优靶点，FDA 的研发路线天然匹配了西方人群。而东亚的最优靶点 A*11:01 和 A*24:02 从来没进过研发管线 [12, 13]。




图 7: TCGA-STAD 非沉默突变类型分布




图 8: 四个 HLA 等位基因的呈递效率对比

表 4: 驱动基因 HLA 覆盖矩阵 (SB 层面)

驱动基因	A*02:01	A*11:01	A*24:02	A*03:01
TP53	✓	✓	✓	✓
PIK3CA	✓	✓	—	✓
ERBB2	✓	✓	✓	✓
KRAS	×	✓	×	✓
CDH1	—	—	✓	—
RHOA	—	✓	✓	✓
CTNNB1	✓	—	✓	—
FBXW7	—	✓	—	—
SMAD4	—	—	✓	—
ERBB3	—	—	—	✓

注：✓= 该 HLA 对该基因至少有一条 SB 肽段；×= 已知驱动基因但该 HLA 无 SB；—= 未检测到或非该 HLA 覆盖范围。KRAS 的 × → ✓ → × → ✓ 格局是全文核心论证支点。




图 9: 各 HLA 的肽段结合强度分布 (percentile rank)




图 10: HLA 驱动基因覆盖的互补性热力图

表 5: 贪心覆盖优化结果

优先级	中国一等位基因	累积覆盖率 (中国)	欧洲一等位基因	累积覆盖率 (欧洲)
FDA 现状	A*02:01	5.0%	A*02:01	26.0%
第 1 优先	A*11:01	46.9%	A*24:02	33.4%
第 2 优先	A*24:02	60.2%	A*11:01	37.1%
第 3 优先	A*02:01	62.2%	—	—

注：使用原始等位基因频率，非 HW 校正携带率。数据来源：HLA 频率 (Zhou 2019[9]/AFND[10]) x 贪心覆盖算法。

用 HW 校正携带率 ($A^*11:01=71.8\%$) 做敏感性分析, 优化排序不变, 覆盖率落在 60%–72% 之间, 结论对方法学假设不敏感。




图 11: 贪心覆盖累积曲线——中国 vs 欧洲




图 12: FDA 现状 vs 优化方案的覆盖率对比

4 讨论

4.1 公平性差距的结构成因

本研究发现 HLA 限制型免疫疗法的公平性差距并非偶然。A*02:01 恰好是欧洲人群的最优靶点，FDA 的研发路线天然匹配西方人群。而东亚的最优靶点 A*11:01 和 A*24:02 从未进入研发管线。这种结构性偏差与 Smithy 等 [12] 和 Oseni 等 [13] 提出的 HLA 异质性驱动型癌症健康差异（HACHD）概念一致——当前治疗策略在未意识到的情况下加剧了健康不平等。

4.2 KRAS 的泛癌种推广

KRAS G12D/G12V/G12C 是泛癌种驱动突变——胰腺癌中约 90%，结直肠癌约 40%，肺腺癌约 30%。胃癌反而是这几个癌种中 KRAS 频率偏低的（约 8–12%）。本研究的发现提供了 lower bound 估计：在 KRAS 突变频率最低的癌种中已经存在显著公平性差距，推广到其他癌种只会更严重 [11]。A*11:01 和 A*24:02 联合覆盖约 60% 中国患者，对药企靶点选择有直接参考价值。

4.3 局限性

（1）肽-MHC 结合预测不等于免疫原性。肽段能稳定结合 HLA 是 T 细胞识别的必要条件，不是充分条件——还需要存在能识别该 pMHC 复合物的 T 细胞克隆 [14, 15]。本研究的定位是必要条件论证：如果连结合都做不到（如 A*02:01 对 KRAS），后续 T 细胞识别就不需要讨论了。

（2）贪心覆盖假设各 HLA 独立分布，A*11:01 和 A*24:02 同处 HLA-A 基因座时存在系统性偏差，经 HW 校正敏感性分析验证排序不变，结论方向稳健。

（3）TCGA-STAD 中亚洲样本仅 87 例 [3]——这是 TCGA 本身的代表性局限。但核心结论不依赖 TCGA 的亚洲样本量：HLA 频率来自独立中国人群队列 [9]，驱动基因验证有独立文献支持，预测对象是公共突变（高频复发）而非个体私有突变。

4.4 后续方向

- （1）扩展至 HLA-B 和 HLA-C 基因座，本研究 4 个等位基因仅为起点；
- （2）用更大规模亚洲胃癌基因组数据补充 TCGA 的代表性不足；
- （3）对 A*11:01 预测最强的若干肽段做体外结合验证；
- （4）将分析框架推广至其他 HLA 限制型疗法适应症（如胰腺癌、结直肠癌）。

5 结论

本研究通过整合 TCGA-STAD 突变数据、IEDB 全矩阵结合预测和贪心覆盖优化，对 HLA 限制型免疫疗法的全球公平性进行了系统性量化分析。主要发现：

(1) A*11:01 的胃癌新抗原呈递能力（27 条 SB）为 A*02:01（11 条）的 2.5 倍，且独有 KRAS 和 FBXW7 的呈递能力。

(2) A*02:01 对 KRAS 的强结合肽段为零，对胃癌突变肽段的强结合判定在统计学上无法与随机肽库区分（富集倍数 0.85x）。

(3) 贪心优化后，中国胃癌患者理论覆盖率从 5.0% 提升至 60.2%（12.4 倍），欧洲仅从 26.0% 提升至 37.1%（1.4 倍）。差距根源在于研发方向的结构性 A*02:01 偏好。

(4) HW 校正敏感性分析验证结论稳健（覆盖率 60%–72%，排序不变）。

综上，HLA 限制型免疫疗法的研发方向存在结构性 A*02:01 偏好，按人群 HLA 分布重排研发优先级可显著缩小公平性差距，尤其对胃癌负担最重的东亚人群。

参考文献

- [1] Nathan P, Hassel J C, Rutkowski P, et al. Overall survival benefit with tebentafusp in metastatic uveal melanoma[J]. *New England Journal of Medicine*, 2021, 385(13): 1196-1206.
- [2] D'Angelo S P, Araujo D M, Abdul Razak A R, et al. Afamitresgene autoleucel for advanced synovial sarcoma and myxoid round cell liposarcoma (SPEARHEAD-1): an international, open-label, phase 2 trial[J]. *The Lancet*, 2024, 403(10435): 1460-1471.
- [3] Cancer Genome Atlas Research Network. Comprehensive molecular characterization of gastric adenocarcinoma[J]. *Nature*, 2014, 513(7517): 202-209.
- [4] UniProt Consortium. UniProt: the universal protein knowledgebase in 2023[J]. *Nucleic Acids Research*, 2023, 51(D1): D523-D531.
- [5] Vita R, Mahajan S, Overton J A, et al. The Immune Epitope Database (IEDB): 2018 update[J]. *Nucleic Acids Research*, 2019, 47(D1): D339-D343.
- [6] Reynisson B, Alvarez B, Paul S, et al. NetMHCpan-4.1 and NetMHCIIpan-4.0: improved predictions of MHC antigen presentation by concurrent motif deconvolution and integration of MS MHC eluted ligand data[J]. *Nucleic Acids Research*, 2020, 48(W1): W449-W454.
- [7] GBD 2021 Causes of Death Collaborators. Global burden of 288 causes of death and life expectancy decomposition in 204 countries and territories and 811 subnational locations, 1990-2021[J]. *The Lancet*, 2024, 403(10440): 2100-2132.
- [8] Bray F, Laversanne M, Sung H, et al. Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries[J]. *CA: A Cancer Journal for Clinicians*, 2024, 74(3): 229-263.
- [9] Zhou Y, Liu S, Yang L, et al. HLA-A, -B, and -DRB1 allele frequencies in Chinese gastric cancer patients[J]. *HLA*, 2019, 93(5): 313-321.
- [10] Gonzalez-Galarza F F, McCabe A, Santos E J, et al. Allele frequency net database (AFND) 2020 update[J]. *Nucleic Acids Research*, 2020, 48(D1): D783-D788.
- [11] Deng N, Goh L K, Wang H, et al. A comprehensive survey of genomic alterations in gastric cancer reveals systematic patterns of molecular exclusivity and co-occurrence among distinct therapeutic targets[J]. *Gut*, 2012, 61(5): 673-684.

- [12] Smithy J W, Blouin A, Diamond L C, et al. Ensuring equity in the era of HLA-restricted cancer therapeutics[J]. Journal for ImmunoTherapy of Cancer, 2022, 10(11): e005600.
- [13] Oseni S O, Wang Y, Hwu P. Advancing human leukocyte antigen-based cancer immunotherapy: from personalized to broad-spectrum strategies for genetically heterogeneous populations[J]. Trends in Cancer, 2025. PMID: 41046167.
- [14] Schumacher T N, Scheper W, Kvistborg P. Cancer neoantigens[J]. Annual Review of Immunology, 2019, 37: 173-200.
- [15] Schreiber R D, Old L J, Smyth M J. Cancer immunoediting: integrating immunity's roles in cancer suppression and promotion[J]. Science, 2011, 331(6024): 1565-1570.